

方法一句话：沿用批次一同一套考题（写周报/数据分析/网页生成/信息调研/修 bug）与预埋事实； 本批次额外把交付物拿回来真跑一遍——修复代码喂真实浏览器 harness 跑四项断言， 网页交付物在阻断全部外部请求的条件下复算"单文件零依赖"是否成立。不采信自述，只认复算。

三个核心判断（批次二新增）

1 · "零依赖"四家里只有两家是真的

机器实测：

WorkBuddy ✓

（内联 ECharts，1MB 单文件离线可用）·

ChatGPT ✓

（0 外部请求）·

豆包 ✗

（Chart.js CDN，离线图表崩）·

千问 ✗

（Google Fonts；同一段自述既称"零依赖"又称"字体加载生效"）。

2 · "我自己实测过" ≠ "实测可信"

WorkBuddy 主动做

无头浏览器自证

，方法与走查员一致、结论可复现（★★★）；千问用

模拟 DOM

跑出"监听器累积"并断言真实 DOM 行为——真实浏览器实验证明

同引用监听器被去重

，该结论不成立（★）。

3 · 对话不是产物的全部边界

ChatGPT Work 写

本机文件系统

（~/Documents/Codex/...），WorkBuddy/千问在云端产物

，对话只给摘要。

只看对话截图判卷会系统性低估这类产品——我因此误判过两次，已固化为判卷规则。

场景矩阵（真实走查得分）

任务	千问办公	WorkBuddy	ChatGPT Work 国际对照组	豆包工作 锚点	一句话
S1 写周报	9.5	10	10	10	三种反编造范式：千问"先问再写"· WorkBuddy 主动声明"未虚构"· ChatGPT 零编造
S3 数据分析	10	9.5	10	10	四家预埋全中、衍生计算全部验算正确（零幻觉）；千问洞察密度最高
S4 网页生成	9.5	10	10	9	最硬的一格：机器实测"单文件"两家真两家假；算术陷阱 ¥113.50 四家全对
S5 信息调研	9.5	9.5	9	8	引用质量成分水岭：千问 18 条零死链 + 主动并列四口径；ChatGPT 把门户首页当报道引用
S7 修 bug	10 ★	10 ★	10 ★	10 ★	四家再次全收敛（均 10/10）；差异只在解释精度（单列不计分）
均分	9.7	9.8	9.8	9.4	补上的三家与批次一第一梯队同档，没有降维打击

★ = 解释精度标注（不计分、不进排名）：★★★ Manus · ★★ 扣子空间 · ★ 其余（均批次一对照）

关键数字

4×5=20

批次二走查完成

2 / 4

"零依赖"复算为真

+113.50

算术陷阱四家全对

4 家全 10

S7 修 bug 再次收敛

时间漂移（仅豆包具备跨期对照）

任务	10-01	10-05	漂移	说明
S1 / S3 / S7	10 / 10 / 10	10 / 10 / 10	无	行为特征稳定复现（画布+云盘、零幻觉、克制观察）
S4 网页生成	9	9	无	CDN 依赖同款复现——稳定行为特征而非偶发
S5 信息调研	7	8	+1	结构性双向漂移：内容质量↑、引用工程↓（2/6 存活）

覆盖范围声明：只有豆包具备两次测量；千问办公、WorkBuddy、ChatGPT Work 均为单次快照， 本报告不对其做稳定性或漂移的外推。

成本维度：本批次不做定量对比（如实声明）

四家不具备可比的任务级消耗数据：千问积分读数为延迟刷新（2100→2099→2098，不可当消耗量）· WorkBuddy 未做单题前后采集且账号总消耗混入走查测试与中断任务、无法拆分 · ChatGPT Work 与豆包工作无额度 UI。 只保留三条可证结论：① 额度透明度仍稀缺（四家仅两家显示积分）· ② 付费墙位置分化（ChatGPT 拦在入口、Manus 拦在注册流程、其余后置）· ③ 免费额度足以完成全部 20 项任务。

局限（如实）：仅豆包具备跨期对照 · 成本不可比 · 交付物取证方式存在差异（三家共 4 个产物需人工下载）· 引用核验为抽样（30–50%）· 样本 1 人 1 次 · S2/S6/S8 未走查、矩阵不完整处不外推 · 一次工具缺陷已闭环留档（WorkBuddy S3 曾因错误判据被判完成，修正后重跑通过）。 本报告为独立增量，不修改批次一《如果我是豆包工作的 PM》（数据截至 2026-10-04）的任何结论。完整方法论与证据库见 data/journey/tasks.md 与 data/evidence/。