

补上盲区之后：WorkBuddy / 千问办公 / ChatGPT Work 问题复测与"单文件"声明的机器复算

4 家 × 5 任务 (S1/S3/S4/S5/S7)

判据生态中立化 (中性层 / 生态层)

数据截至 2026-10-06

走查 10-05 ~ 10-06

作品集 · 第一期·批次二

与批次一的关系：本报告是独立增量，不修改批次一《如果我是豆包工作的 PM》的任何结论。批次一覆盖豆包工作 / Kimi / 扣子空间 / Manus，数据截至 2026-10-04；批次二补入 千问办公、WorkBuddy，并以 豆包工作为锚点做跨期复测，以 ChatGPT Work 为国际对照组。方法框架、证据分级五规范、走查判据沿用批次一（见其 §10 与 `data/journey/tasks.md`），本报告只写新增证据与新增判断。

口径对照表

批次一评审存在一个盲区：把"通用 AI 入口的领跑者"与"AI 办公智能体品类的领跑者"混为一谈。本表把两条赛道的口径显式分层——两套口径不混用、不合并排名。

产品	批次一称谓	P2 称谓	规模数据依据 (口径)
豆包工作 (字节)	领跑者 (报告主角)	锚点 + 品类挑战者	豆包 App 3.82 亿 MAU (QuestMobile 2026-08) — 通用 AI 入口口径
WorkBuddy (腾讯)	未入实测 (名单评审盲区, 已如实交代)	AI 办公智能体品类现任领跑者	约 2000 万 MAU (QuestMobile PC 658 万 7 月 → Xsignal 破 1000 万 8 月 → 约 2000 万 9 月) — 品类口径
千问办公 (阿里)	备选 (未入实测)	品类挑战者 (阿里系)	公测 8-3, 注册用户破 3000 万 (企业用户过半) — 品类口径
ChatGPT Work (OpenAI)	未纳入	国际对照组 (连接器型)	官方 Workspace Agents 定位; 竞争集合为 Copilot / Gemini in Workspace, 不与国内三家同表排名

为什么必须分层：如果把"豆包 3.82 亿 MAU"与"WorkBuddy 2000 万 MAU"放进同一个"领跑者"结论里，读者会得出"豆包是办公品类第一"的错误推论。两条口径服务两个不同问题：通用入口看豆包、办公智能体品类看 WorkBuddy。

批次二场景矩阵（真实走查得分）

4 家 × 5 任务。ChatGPT Work 为连接器型产品，按判据中立化设计单列标注；豆包工作为锚点，其"批次一 → P2"两列用于时间漂移检验。

任务	千问办公	WorkBuddy	ChatGPT Work 国际对照组	豆包工作 锚点	走查关键发现
S1 写周报	9.5 ●	10 ●	10 ●	10 ●	三种反编造范式同台：千问"先问再写"（唯一把防编造前移到输入验证，附数据缺口清单）· WorkBuddy 主动声明"仅用记录中的真实数字、未虚构"· ChatGPT 零编造（10 秒最快）
S3 数据分析	10 ●	9.5 ●	10 ●	10 ●	四家预埋事实全中、衍生计算全部验算正确（零幻觉）。千问洞察密度最高（剔除西南后三区萎缩）；ChatGPT 计算代码与 PNG/SVG 导出物入库；WorkBuddy 建议含量化目标但无单图导出
S4 网页生成	9.5 ●	10 ●	10 ●	9 ●	本报告最硬的一格：机器实测"单文件零依赖"——WorkBuddy ✓、ChatGPT ✓、豆包 ×（Chart.js CDN）、千问 ×（Google Fonts，且自述"零依赖"与事实矛盾）。全部四家算术陷阱 ¥113.50 均验算通过
S5 信息调研	9.5 ●	9.5 ●	9 ●	8 ●	引用质量成为分水岭：千问 18 条零死链 + 主动并列四种口径；WorkBuddy 11 条 10 条存活；ChatGPT 把 门户首页当作报道引用；豆包 4 条引用 2 条失效（含 U+2011 系统性截断）。四家均需人工抽查引用后使用

S7 修 bug	10 ● ★	10 ● ★	10 ● ★	10 ● ★	四家再次全收敛（均 10/10），修复代 码经真实浏览器 harness 实测全部通 过。差异在解释精度（见下"解释精 度"表），已按统一口径单列标注、不 计分
均分	9.7	9.8	9.8	9.4	WorkBuddy 与 ChatGPT Work 并列 第一。批次二没有出现"降维打 击"——补上的三家与批次一第一梯队 同档

● 强 (≥8) · ★ = 解释精度标注（不计分、不进排名）。每格可回溯至 `data/evidence/{产品}/{任务}/` 的截图、产出物与 harness 结果。

批次二新增的四个判断维度

这四个维度在批次一里无法得出结论——它们要么由国际对照组引入，要么由"把交付物真正拿回来跑一遍"才暴露。

① 交付形态三态：判卷必须同时查"对话侧"与"文件系统侧"

file:// 落到本机磁盘（ChatGPT Work）

交付物写在 `~/Documents/Codex/...`、`~/.codex/visualizations/...`，对话里只给功能摘要。它的 S3 图表（PNG 1600×820 + SVG）与计算代码都在磁盘上，对话里看不到。

云端产物（WorkBuddy / 千问）

WorkBuddy 的 `个人记账本.html`、调研报告、`todo-fixed.html` 都在云端产物面板；千问给出 `presigned_url` 可直取。两者都需要额外一步"把文件拿回来"。

方法论教训（已写进方法记录）：只看对话截图判卷，会系统性低估交付物落在文件系统的产品。我在同一个坑里踩了两次——S7 只看文件名没打开图就断言"缺解释"；S3 只看对话就断言"图表不能导出、没有计算过程"。两次的证据其实都在磁盘上。**规则：判卷须同时检查对话侧与文件系统侧。**

② "单文件 / 零依赖"：第一次有了机器复算的确定性证据

产品	自述	机器实测（阻断外部请求后打开）	判定
----	----	-----------------	----

WorkBuddy S3/S4	"零依赖、可离线双击打开"	S4 应用 0 外部请求；S3 报告 1,050,275 字节内联 ECharts，离线渲染出 3 张图表	✅ 属实
ChatGPT Work S4	单文件、零依赖	联网与离线两种模式均 0 外部请求，增量 +113.50 正确	✅ 属实
豆包工作 S4	"单文件 HTML"	外链 <code>cdn.jsdelivr.net</code> (Chart.js)；离线抛 <code>Chart is not defined</code>	❌ 不成立
千问办公 S4	"零依赖，可离线打开"	加载 3 张 Google Fonts（联网 20 个外部请求）；同一段自述里又称"三张 Google Font 加载生效"	❌ 不成立 (自述自相矛盾)
Kimi / 扣子空间 / Manus（批次一）	零 CDN / SVG 无依赖	当时仅做源码核验或未归档产物，无法机器复算	🕒 未验证

结论：同一句"零依赖"，四家里只有两家经得起复算。这不只是工程严谨性问题——千问在同一段交付说明里既称"零依赖"又称"三张 Google Font 加载生效"，属夸大交付属性，与批次一 Kimi 的"静默虚构"同属"自述不可靠"这一族信任风险。

③ 自证可信度：产品自己做的"实测"值不值得信

产品	自证行为	走查员复算	评级
WorkBuddy	主动声明"已验证（无头浏览器实测）：16 条示例数据 → 7 个扇区、合计 ¥6,716.47"	其验证方式与我方 harness 一致；离线渲染与数值均复现通过	★★★ 主动自证且方法一致
千问办公	称"我用一个模拟 DOM 跑了一遍"，给出"click 监听数 1→2→3"并断言真实 DOM 会派发多次	真实浏览器对照实验：同一函数引用注册 3 次 → 点击触发 1 次（浏览器去重）——该结论不成立	★ mock 当实测，结论失真
豆包工作 / ChatGPT Work	豆包 S7 未跑代码但机制判断正确；ChatGPT 称"已通过语法检查和连续点击测试"	ChatGPT 的声明与 harness 结果一致	★★ 声明与实测相符

"我自己实测过" ≠ "实测可信"——关键要看它在什么环境里证。千问用 mock DOM 产出了一个真实浏览器里不存在的现象；WorkBuddy 用真无头浏览器，结论可复现。这条与批次一"链接都能打开、内容却对不上"（Kimi）属同一族：验证动作看起来充分，验证对象不忠实。

④ 解释精度（S7 单列，不计分）

P2 的 S7 再次四家全收敛（均 10/10）。按统一口径，"原因解释正确"只判是否~~正确~~定位成因；解释的精细程度单列标注、不参与均分——否则一个措辞细节会削弱"修 bug 能力已成标配"这一能力层结论。

解释精度	产品	依据
★★★	Manus（批次一）	唯一指出"浏览器对同一元素、同一事件类型、同一函数引用会去重，因此该 bug 未必在运行时复现"——走查员实验证实其判断正确
★★	扣子空间（批次一）	唯一把越界产生的幽灵项正确描述为"空白 "（与实测一致；豆包/Kimi/千问/WorkBuddy 均称"undefined"）
★	豆包 / Kimi / 千问 / WorkBuddy / ChatGPT	教科书式描述"重复绑定 → 一次点击新增多条"，在真实浏览器下不成立（去重），但成因定位正确

时间漂移检验（豆包工作锚点）

锚点唯一用途是回答"这些产品在几天内会变吗"。批次一 10-01、批次二 10-05 问题复测。

任务	10-01	10-05	漂移	复现情况
S1 写周报	10	10	无	文档画布 + 云盘同步复现；生成更快（45 秒）
S3 数据分析	10	10	无	三个预埋事实全中、零幻觉；同款技能链路
S4 网页生成	9	9	无	CDN 依赖同款复现 ——属交付管道的稳定行为特征，非偶发
S5 信息调研	7	8	+1	结构性双向漂移 ：内容质量上升（覆盖五玩家），引用工程恶化（U+2011 截断致 2/6 存活）
S7 修 bug	10	10	无	双 bug 全中 + 同款"已完成 n 项"语义观察
均分	9.2	9.4	+0.2	4 任务零漂移 + 1 任务结构性双向漂移

锚点结论：豆包的行为特征（零编造 / CDN 交付习惯 / 克制不越界 / 引用排版缺陷）在时间维度上 **稳定可复现**——锚点有效，跨期对照基线成立。

但必须声明覆盖范围：只有豆包具备两次测量；千问办公、WorkBuddy、ChatGPT Work 均为**单次快照**，本报告不对其做稳定性或漂移的外推。

成本维度：本批次不提供跨产品定量对比（如实声明）

批次二的成本数据经逐家核查后确认**不可比**，故只做定性比较——不做假对比。

产品	额度机制	消耗可观测性	能否用于定量对比
千问办公	积分（注册 2100）	界面显示余额	❌ 读数为延迟刷新（2100→2099→2098，短期不动），归因不确定，不可当消耗量
WorkBuddy	积分（注册 2000 = 500+1500）	界面显示余额	❌ 未做单题前后采集；账号总消耗又混入走查过程中的测试与中断任务，无法拆分
ChatGPT Work	免费档，无积分 UI	不可观测	❌ 无数据
豆包工作（锚点）	免费版 + 订阅档	无额度 UI	❌ 无数据

为什么不做：把"千问每任务读数差 1 点"与批次一"扣子调研任务 32% 积分"并排，是假对比——两者粒度不同、读数可靠性不同。本报告的成本层只保留三条**可证的**定性结论：

- **额度透明度仍然稀缺**：本批次四家中，只有千问与 WorkBuddy 显示积分余额；ChatGPT Work 与豆包工作无额度 UI，用户对消耗零感知。
- **付费墙位置分化**：ChatGPT Work 网页版在入口处即拦（"使用 Plus 解锁"），Manus 在注册流程内展示（批次一），其余各家均为后置（点击"升级"才出现）。
- **免费额度足以完成全部走查**：四家 20 项任务无一因额度中断（"额度不足"的预设风险未出现）。

批次一的可信定量结论（扣子调研 32% · 复走 39%/38% 收敛 · Manus 三任务 406/1300 · Manus S7 仅 1 积分）**仍然有效**，但来源为批次一、数据截至 2026-10-01，本报告仅引用不作外推。

对批次一三条策略建议的增量

批次一给豆包工作 PM 的三条建议（反幻觉心智 / 工程交付严谨性 / 用量透明层）在批次二得到了新证据。

建议 1「忠实性 + 引用健康度产品化」→ 证据增强

批次一只有 Kimi 一家反面样本；批次二补到两家：千问 S4 夸大交付属性（"零依赖"vs Google Fonts）、ChatGPT S5 把门户首页当报道引用。"自述不可靠"是这条赛道的结构性问题，不是个别产品缺陷。

建议 2「补齐工程交付严谨性」→ 出现了可对标的样板

WorkBuddy 把 ECharts 内联进 1MB 单文件、真正离线可用——这就是"外链资源 = 0"发布门禁落地后的样子。豆包若补上这条门禁，可直接对标这一实现。

建议 3「用量透明层」→ 品类内仍无人做好

四家里只有两家显示积分余额，且没有一家做任务级消耗可视化。批次一建议的"用量透明层"在批次二依然空位——这既是豆包的机会，也说明这条建议的窗口仍然开敞。

新增建议 4（面向品类）：「自证须可复算」

产品开始主动输出"我已验证"的声明。建议把自证做成可复算的证据（附 harness / 复现步骤），而不是一句结论——否则会像千问那样，用 mock 环境产出真实环境不存在的现象，反而损伤信任。

方法论、局限与数据来源

走查执行摘要

2026-10-05 ~ 10-06 · 四家 × 五类任务（S1 写周报 / S3 数据分析 / S4 网页生成 / S5 信息调研 / S7 修 bug），统一 prompt 逐字一致、预埋事实抓幻觉（销售数据 3 处、bug 代码 2 处）。本批次全部任务由走查员通过 CDP 驱动真实浏览器执行（WorkBuddy / 千问），或由用户人工执行 + 走查员判卷（ChatGPT Work 桌面 App）；修复代码与网页交付物均经真实浏览器 harness 实测（tools/verify-s4.py、tools/verify-s7.py）。

局限声明（如实）

- 仅豆包具备跨期对照：其余三家为单次快照，不做稳定性外推；
- 成本不可比：本批次四家不提供任务级、可比口径的消耗数据（见"成本维度"节）；
- 交付物取证存在差异：ChatGPT Work 的产物在文件系统、WorkBuddy 与千问在云端、且需用户手动下载其中三家共 4 个文件；未取得的产物已在各走查记录中标注为"未机器验证"；
- 引用核验为抽样：S5 各家的引用抽查比例约 30-50%，非全量；

- 一次工具缺陷已闭环并留档：WorkBuddy S3 首次走查被"文本静默即完成"的错误判据误判（产物面板实为空），修正为"以产品完成标记为准"后重跑通过——判据设计错误会把产品的正常行为记成缺陷；
- 样本仍为 1 人 1 次（每产品），非可用性测试；
- S2 / S6 / S8 仍未走查（范围决策，矩阵不完整处不外推）。

数据来源与证据库

- 一手走查证据（A 级）：`data/evidence/{qwen-work,workbuddy,chatgpt-work,doubao-work}/`——截图、产出物源码、对话转录；
- harness 输出（A 级）：`data/evidence/_harness/`——S4 单文件/算术验证、S7 四项断言、同引用监听器去重对照实验；
- 判据与预埋事实设计（A 级）：`data/journey/tasks.md`（含 P2 生态中立化口径、S7 解释分口径裁定）；
- 各产品走查记录：`data/journey/{qwen-work,workbuddy,chatgpt-work}.md`；
- 桌面调研（B/C/D 级）：见批次一报告 §10 来源表与 `data/products.yaml`。

AI Office Compass · 批次二（P2）· 数据截至 2026-10-06 · 一手走查 4 产品 × 5 任务 = 20 项

本报告为独立增量，不修改批次一《如果我是豆包工作的 PM》（数据截至 2026-10-04）的任何结论。

方法论与需求详见 PRD v2.2 §6.5 · 判据详见 `data/journey/tasks.md`