

如果我是豆包工作的 PM：C 端 Agent 办公赛道竞品分析与策略建议

正式版 v1.4 (20/20 + 复走 + 口径分层补记)

数据截至 2026-10-04 (走查 10-01 + 复走 10-04)

参赛作品：4 个 · 走查任务 5 类 × 4 家 (含 S7 补测)

作品集 · 第一期

✅ 本报告基于真实一手走查：四家产品各完成 S1 写周报 / S3 数据分析 / S4 网页生成 / S5 信息调研，并于 10-01 晚补测 S7 修 bug (统一 prompt、预埋事实抓幻觉、逐项验算，修复代码均经走查员本地 harness 实测)，全程截图与产出物存档于项目仓库 **data/evidence/** (77 张截图、19 份产出转录)。走查条件与局限见 §10。S2/S6/S8 三类任务未走查 (范围决策见方法论)。

TL;DR · 三个核心判断

全部由一手走查数据支撑，每条判断可在对应章节复核证据。

判断 1 · 忠实性成为分层变量

"替你干活"的产品已经开始分化：谁来保证"干的是你交代的事"?

同一写作任务，豆包/扣子严格只用给定数据，Kimi 为丰富"亮点"虚构 4 处细节 (§5)，Manus 用占位符+显式声明 (§4)。忠实性差异用户极难察觉——却是企业采用的第一道信任门槛。

判断 2 · 没有全能冠军

五类任务没有全能冠军：写作看豆包/扣子，生代码看 Kimi，调研看扣子/Manus，修 bug 四家全对

走查均分 8.7-9.6 高度接近，但分任务冠军完全不同 (§5 矩阵)；唯一全收敛的 S7 修 bug 说明基础修复已成标配、质量分层转向解释精度。"选哪家"取决于任务结构，通用横评排名正在失效。

判断 3 · 成本与组织整合重塑格局

调研任务烧掉扣子 32% 积分；字节 7-8 月完成组织收编，QClaw 停运

Agent 产品的成本结构首次被实测 (§6)：调研类任务消耗是普通任务 5-30 倍。组织侧，Aily 更名豆包工作伙伴 (8-13)、QClaw 停运 (9-24) 标志赛马结束、入口集中 (§2)。

场景速查表 · "我的任务该用谁" (基于真实走查)

每行对应一类走查任务的实际得分与证据，详细依据见 §5 矩阵

任务	首选	备选	走查证据 (一句话)
日常写作 / 周报 (S1)	豆包工作 · 10 分	扣子空间 · 10 分	豆包自动转文档+云盘；扣子 20 秒最快；两家均零编造。Kimi 虚构 4 处细节
数据分析 / 图表 (S3)	豆包 / 扣子 / Manus · 9.5-10	Kimi · 9.5	罕见收敛：预埋事实全部命中、零幻觉；Kimi 额外发现"华北反超华东" (验算为真)
网页 / 小工具 (S4)	Kimi · 10 分	Manus · 9.5 分 (人工补测)	Kimi 零 CDN 真·单文件 (源码核验)；Manus 用户补测通过 (合计 ¥113.50)；豆包 CDN 依赖扣 1 分
信息调研 / 报告 (S5)	扣子空间 · 9 分	Manus · 9 分	扣子 6/6 链接全绿+后台异步；Manus 6 子代理核验+拒绝编造排名。**均需人工抽查引用** (豆包死链、Kimi 锚点错位)

任务	首选	备选	走查证据（一句话）
修 bug（S7）	四家均 10 分（罕见全收敛）	—	预埋 2 bug（越界+重复绑定）全中、修复经本地实测全部通过；差异在解释精度：Manus 识破"去重型隐性 bug"、扣子表象描述唯一与实测一致

🚩 得分档位：● 强（≥8）· ● 中（6-7.9）· ○ 弱（4-5.9）· —（无法完成/未达）。走查判据与预埋事实见 data/journey/tasks.md。

赛道与选手

一屏看全 4 个产品的关键事实（含走查期交叉修正：豆包工作统合时间线、豆包 MAU 更新至 3.82 亿）。

产品	所属	关键节点	一句话定位	底座	定价（走查核实）	用户规模	增长机制
● 豆包工作	字节跳动	2026-06-24 收费 · 07/08 统合 ^[1]	泛 C 端 AI 办公入口：任务后台执行、可接管	豆包大模型（自研）	免费 / 68 / 200 / 500 元·月	MAU 3.45 亿（Q1）→ 3.82 亿（8 月，QuestMobile） C	字节系导流 + 投流 + 飞书 context
● Kimi	月之暗面	2026-04 K2.6 开源 · 07 会员重构 ^[2]	聚焦智能上限：长程任务与 Agent 集群	K2.6 / K3（自研 + 开源）	49 / 99 / 199 / 699 元·月（重构中）	第三方口径"掉队"，官方未披露 D	技术口碑 + 开源社区
● 扣子空间	字节跳动	2025-04 上线 · 域名已并入 coze.cn ^[3]	通用 Agent 协作平台：60+ MCP 扩展	豆包系 + 多模型路由	免费（每日 1500 积分）/ 39.9 / 99 元·月	未公开 D	开发者社区 + 模板市场
● Manus	Monica（Meta 收购）	2025-03 发布 · 2026-03 被收购 ^[4]	通用 Agent：沙盒虚拟机 + 子代理编排	Claude/GPT/Qwen 聚合	Free / \$19 / \$39 / \$199 月	留存长期低位（媒体口径） C	海外社区 + replay 传播

数据截至 2026-10-01 · 豆包工作统合时间线经走查期多源交叉修正（原 M1 档案误记 2025-08，由 Manus 报告声明"飞书 Aily 更名豆包工作伙伴"触发外部核验，QQ 新闻 2026-08-21 证实 8-13 更名、7-30 飞书组织调整）^[1]。豆包 MAU 3.82 亿为 QuestMobile 2026-08 口径 **C**。

赛道边界与落选说明（2026-10-04 补记）

口径声明：本报告的"办公赛道"指 **C 端 Agent 产品的办公任务实测**，不是"纯办公品类产品清单"——四家按格局代表性入选（领跑者 / 智能上限口碑 / 平台型 / 兴衰样本，判据见 PRD §6.1），S1-S7 任务全部为办公任务。纯办公位选手与本报告的关系如下：

口径注（2026-10-05 补记）：本卡中"领跑者"与"第一"分属两条赛道——豆包工作的"领跑者"指**通用 AI 入口与生态口径**（豆包 App 3.82 亿 MAU）；WorkBuddy 的"第一"指**AI 办公智能体品类 MAU 口径**（约 2000 万）。两口径不混用，批次二起显式分层并设口径对照表（PRD §6.5）。

产品	定位与规模（多源）	未入第一期实测的原因	去向
WorkBuddy（腾讯）	纯办公位 · 2026-03 上线 · 办公智能体细分 MAU 现任第一 （QuestMobile 7 月 PC 端 658 万 → Xsignal 8 月破 1000 万 → 9 月约 2000 万 / DAU 1300 万，DAU/MAU 65-75%） C	名单评审盲区，如实交代：9-13 定名单时未捕获其规模数据线；10-04 复盘捕获后列为批次二首位补测对象	批次二实测（首位）

产品	定位与规模（多源）	未入第一期实测的原因	去向
千问办公（阿里）	纯办公位 · QoderWork/悟空/MuleRun 三合一 · 8-3 公测 · 9-4 用户破 3000 万（企业用户过半）· 78 元/月起 · 独立客户端 8 月 MAU 158 万（AI 办公智能体增速榜第二） C	企业用户占比过半、C 端纯度弱于第一期四家；名单评审时客户端规模数据未进入视野	批次二实测
ChatGPT Work（OpenAI）	国际对照组 · GPT-5.6 职场智能体 + Workspace Agents（4-22 起面向 Business/Enterprise） C	任务层可比，但竞争集合不同（对手是 Copilot / Gemini in Workspace，不与国内四家出现在同一张采购对比表）；生态策略为"连接器型"（不自建网盘，产物不自动落位）	批次二以"国际对照组"进入，判据先做生态中立化改造


批次二方案（P2，2026-10-04 定稿并启动）：千问办公 + WorkBuddy + 豆包工作（锚点：跨期可比 + 时间漂移检验）+ ChatGPT Work（国际对照组）× 同一套 S 题（S1/S3/S4/S5/S7）；判据拆"中性层（全体可比）/ 生态层（单列标注）"两层口径。命名注：本项目"第二期"保留给大模型横评，本批次记作 P2。

战略定位图

横轴：目标用户（专业/开发者 ↔ 泛大众）；纵轴：任务模式（对话辅助 ↔ 自主执行）。

C 端 Agent 办公产品定位（2026 H2，走查后修正）

气泡位置综合走查观察（任务范式/入口设计/Agent 化程度）；悬停查看走查依据



走查修正：扣子空间独立域名 space.coze.cn 已整站跳转 coze.cn——"平台+空间"双线收编为单一入口，字节的 Agent 矩阵（豆包工作/扣子/TRAE）全部汇入豆包主品牌^[1]。

用户旅程走查（S0 注册 + 首任务）

统一条件：新注册账号、同一设备。S0 为用户亲自注册的记录（截图存证），首任务生成时长来自走查计时。

注册到首任务可用 · 关键数字

S0 注册（步数/耗时/付费墙位置）+ S1 首任务生成时长



一手走查（证据等级 A）· 数据截至 2026-10-01 · 局限：样本 1 人 1 次。 **付费墙位置是关键差异**： Manus 在注册流程内即展示（商业化前置），国内三家全部后置到"点击升级"。

产品	注册步数	注册耗时	付费墙位置	S1 生成时长	额度 UI	首任务 aha 时刻
● 豆包工作	1	<1 分钟	注册全程无，点击"升级"才出现	约 1 分钟	无额度 UI	周报自动转文档画布 + 云盘同步
● Kimi	1	<1 分钟	同上（后置）	<30 秒	无额度 UI	思考轨迹可见（"要不要追问？不，直接产出"）
● 扣子空间	2	约 1 分钟	同上（后置）	约 20 秒	积分轨迹透明（100%→37%）	周报任务 20 秒交付 + 转文件追问
● Manus	3	3 分钟	注册流程内（第 3 步，可跳过）	31 秒	积分明确（1300 = 1000+300）	沙盒虚拟机写文件 + 主动声明两处推断

数据来源： S0 用户注册记录 + 走查计时（证据截图 evidence/*/S0/）。Manus 积分口径经 S0 截图实证（A 级）。

场景覆盖矩阵（真实走查得分）

五类任务（含 S7 补测批次）× 四个产品，每格为走查实测得分（0-10）与档位。S2/S6/S8 未走查（范围决策： S1/S3/S4/S5/S7 已覆盖"写作、数据、生成、调研、修 bug"五类核心任务，见 §10）。

任务	豆包工作	Kimi	扣子空间	Manus	走查关键发现
S1 写周报	10 ●	7 ●	10 ●	9.5 ●	Kimi 数据亮点节虚构 4 处细节（"用时 1 周"等输入外信息）； Manus 留占位符+声明推断； 10-04 复走： 豆包画布/云盘仅在「新对话」入口触发，「新工作任务」入口为普通聊天（入口能力不一致）

任务	豆包工作	Kimi	扣子空间	Manus	走查关键发现
S3 数据分析	10 ●	9.5 ●	9.5 ●	9.5 ●	预埋事实全部命中、零幻觉（四家收敛）；衍生指标逐项验算正确；Kimi/扣子均自修复脚本报错
S4 网页生成	9 ●	10 ●	9.5 ●	9.5 ●	功能全对；差异在工程严谨性：Kimi 零 CDN 真·单文件（源码核验）> 扣子 SVG > 豆包 CDN 依赖；Manus 由用户人工补测通过（两笔合计 ¥113.50 正确）
S5 信息调研	7 🟡	7 🟡	9 ●	9 ●	四家均真搜索；引用质量分化：扣子 6/6 全绿、Manus 拒绝编排名、豆包 1 死链、Kimi 锚点错位；10-04 复走另见扣子 1 处主体归属错位（"2000 万企业"张冠李戴）——"链接能打开"仍需抽查内容归属
S7 修 bug（10-01 补测）	10 ●	10 ●	10 ●	10 ●	预埋 2 bug（越界+重复绑定）四家全中，修复经本地 harness 实测全部通过；差异在解释精度：Manus 唯一识破"同引用监听器被浏览器去重、bug 未必复现"，扣子唯一正确描述幽灵项为空白 li，豆包主动指出计数语义歧义且克制不越界
S2 做 PPT	未走查	未走查	未走查	未走查	范围决策：第一期聚焦高频核心任务，S7 已于 2026-10-01 补测批次完成（四家全收敛）；S2/S6/S8 留待后续补齐——已覆盖任务足以支撑核心判断，矩阵不完整处如实标注，不做外推。
S6 生活规划	未走查	未走查	未走查	未走查	
S8 长文档对比	未走查	未走查	未走查	未走查	

每格得分可回溯至 evidence/{产品}/{任务}/ 的截图与产出文件（77 张截图、19 份产出转录）。


商业化对比

定价经 M1 桌面调研核实（B 级证据）；成本结构为本次走查的独有实测数据。

订阅定价对比（RMB / 月，走查核实口径）

浅色 = 入门档 · 实色 = 进阶档 · 悬停查看档位说明

● 浅色 = 入门/标准档 ● 实色 = 高阶档 豆包另有加强版 ¥200/月 · Kimi 另有 ¥699 · Manus 另有 \$199（Team）· 扣子另有旗舰/尊享档



豆包 2026-06-24 收费（免费版保留）^[1]；Kimi 49/99/199/699 四档（会员体系重构中）；扣子 39.9/99 + 积分制（1000 积分 = 1 元，每日登录领 1500）；Manus \$19/\$39/\$199（折算按 7.15，采集日 2026-09-13）。

产品	免费额度实测	付费墙位置	成本结构观察（走查实测）
● 豆包工作	宽松：四任务全部完成，无额度提示	后置（升级入口）	无额度 UI = 体验顺滑，但用户对消耗零感知；已收费（68-500 元）——免费策略与收费体系的衔接是信任关键点
● Kimi	中等：四任务完成；会员重构期曾暂停新订阅（7-19）	后置	推理成本高（K2.6/K3），靠订阅 + API + 开源三线分摊
● 扣子空间	新号 3000 积分；**实测消耗轨迹：100%→99%（S1）→76%（S3/S4）→37%（S5 后）→33%（S7 修 bug 后）**	后置	**调研任务消耗约 32% 积分（≈960/3000），是普通任务的 5-30 倍**——“调研最贵”有了实测数据；S7 修 bug 约 4%（≈120），介于写作与调研之间；**消耗轨迹实时可观测为四家唯一**（侧栏百分比随任务推进可见），但展示为百分比而非精确数字，任务级消耗需由差值推算
● Manus	1300 积分（1000+300）；S1/S4/S5 消耗 406；S7（Lite 直答）**仅 1 积分**，余 876	注册流程内即展示（前置）	**积分余额数字最明确**（具体数值前置展示，S0 截图实证）；但走查期间任务级消耗无实时轨迹，仅有前后差值；24 分钟子代理调研为大额消耗项，**Lite 档直答类任务近乎免费（S7=1）**

扣子积分轨迹与 Manus 消耗为本次走查独有的成本实测（A 级证据）；“免费额度不足”的预设风险未出现——四家免费档均足以完成全部走查任务。**透明度维度对比**：扣子 = 消耗轨迹可观测（实时百分比、任务间可归因，但非精确数字）；Manus = 余额数字明确（具体值前置展示，但无实时轨迹）——两种透明各有盲区；豆包/Kimi 两者皆无。**重复测量（2026-10-04 复走）**：独立新账号重测扣子调研任务消耗 **38%**，与首测 **39%** 收敛（两个干净样本、间隔 3 天）；第三样本因并发任务污染仅作参考。

底座与工程纵深

走查揭示了底座差异如何传导为产品行为差异——这是本报告区别于一般产品横评的部分。

产品	底座与执行架构	走查可见的传导（一手证据）	对成本/商业的含义
● 豆包工作	豆包大模型（自研）+ 内置技能体系（ECharts 规范、文档画布）	S1 自动转文档+云盘；S3 先读自家可视化技能规范再出图——**深度协同是真实的产品能力，非营销话术**（截图 00-01）；S7 双 bug 全中并主动指出计数语义歧义、克制不越界	自研边际成本可控 → 免费策略可持续；但 S4 CDN 依赖暴露工程交付的严谨性缺口

● Kimi	K2.6/K3（自研+开源）+ Python 沙盒执行	S3/S4 真实执行 Python 出图出文件；S4 交付零 CDN 真·单文件——**代码执行能力直接转化为交付质量**；S7 为 K3 首批实测	推理成本高 → 订阅分层 + 会员重构（权益拆分）
--------	-----------------------------	--	---------------------------

产品	底座与执行架构	走查可见的传导（一手证据）	对成本/商业的含义
		(kimi.com 已默认 K3)，双 bug 全中、小结表+经验之谈结构最完整	
● 扣子空间	豆包系 + 多模型路由 + 技能/规范体系 (html-artifact-create + implementation contract)	S4 先读实现契约再建页；S3 脚本报错**自我修复重算**——工程流程最完整；但也交付了日期时区 bug；S7 唯一正确描述幽灵项表象（空白 li，与实测一致）	积分制对冲线性成本；调研任务 32% 积分消耗为定价提供依据
● Manus	Claude/GPT/Qwen 聚合 + **沙盒虚拟机 + 6 子代理并行编排**	S1 在 ubuntu 沙盒写文件；S5 六路并行核验并"统一判断证据强度，避免只罗列产品宣传"，**主动拒绝未经证实的精确排名**；S7 Lite 直答仅 1 积分，**唯一识破"同引用监听器被浏览器去重、重复绑定未必复现"的隐性 bug 本质**	24 分钟子代理调研为大额消耗（S1+S4+S5 = 406/1300 积分）；聚合毛利受上游挤压

关键结论：底座差异同时决定体验上限（§5）与成本结构（§6）——聚合型（Manus）用编排纪律补偿质量不确定性，自研型（豆包/扣子）用深度协同换成本空间，Kimi 用代码执行换交付质量。S7 批次新增信号：**修 bug 能力四家全收敛（均 10 分），质量分层已转移到解释精度层面**——这是赛道成熟度的直接证据。

单产品卡片·画像与 SWOT（走查实证版）

SWOT 全部条目对应走查证据，可在 data/evidence/ 复核。

● 豆包工作 字节·自研底座·均分 9.2

注册 1 步 <1 分钟 免费 / 68 / 200 / 500 元 MAU 3.82 亿 (8 月)

泛 C 端入口：任务后台执行、文档画布、云盘一体；字节 7-8 月完成 TRAE/扣子/飞书 Aily 的组织收编。

STRENGTH · 优势（实证）

四家最顺滑（注册 1 步、无打断）；S1/S3 零编造零幻觉；文档画布+云盘体验最佳；S7 双 bug 全中+主动指出计数语义歧义

WEAKNESS · 劣势（实证）

S4 CDN 依赖 ("单文件"不严格)；S5 调研 1 死链+1 数字未命中引文；无额度 UI 用户零成本感知

OPPORTUNITY · 机会

忠实性+引用质量可产品化为"反幻觉"卖点；组织收编完成后飞书企业 context 是独占资产

THREAT · 威胁

扣子空间同门竞争（忠实性与成本透明均略优）；Kimi 在生成类任务的质量口碑

● Kimi 月之暗面·自研+开源·均分 8.7

注册 1 步 <1 分钟 49 / 99 / 199 / 699 元 K2.6 开源 / K3

聚焦智能上限：Python 沙盒真实执行、代码交付质量最高；C 端流量与商业化在重构期。

STRENGTH · 优势（实证）

S4 满分（零 CDN 真·单文件）；S3 额外洞察经验证为真（华北反超华东）；Python 执行透明；S7 K3 首测满分

WEAKNESS · 劣势（实证）

S1 数据亮点节虚构 4 处细节（静默、无声明）——四家唯一；S5 引用锚点 2/4 对不上原文

OPPORTUNITY · 机会

生成类任务质量口碑（S4 满分）可扩散至开发者人群；K3 + 海外云合作

THREAT · 威胁

虚构细节若被企业用户发现即信任崩塌；入口流量弱于大厂

● 扣子空间 字节·Agent 平台·均分 9.6

注册 2 步约 1 分钟 免费 3000 积分 / 39.9 / 99 元 积分消耗全程可观测

通用 Agent 协作平台：技能+实现契约的工程化流程，后台异步任务不阻塞对话；域名已并入 coze.cn。

STRENGTH · 优势（实证）

WEAKNESS · 劣势（实证）

均分四家最高；S5 链接 6/6 全绿；忠实性与豆包并列；20 秒交付速度最快；S7 幽灵项表象描述唯一与实测一致

OPPORTUNITY · 机会

成本透明+工程流程（实现契约）是企业采购最看重的两项，可放大为 B 端卖点

交付网页存在日期时区真 bug（重置为前一天）；图表无单图导出；上手概念多（积分/Agent/项目）；复走另见引用 1 处主体归属错位

THREAT · 威胁

与豆包工作同门左右互搏；调研类任务积分消耗高企（32%）可能劝退重度用户

● Manus 聚合型 · 均分 9.4

注册 3 步 3 分钟 (付费墙前置)

Free 1300 积分 / \$19 / \$39 / \$199

沙盒 VM + 子代理

通用 Agent: 沙盒虚拟机 + 6 子代理并行核验, 证据纪律四家最强 (拒绝编造排名、推断显式声明)。

STRENGTH · 优势（实证）

S1 占位符+推断声明（反编造最佳实践）；S5 拒绝未证实排名；S4 用户实测通过（合计 ¥113.50）；S3 交付 5 文件；S7 唯一识破去重型隐性 bug

WEAKNESS · 劣势 (实证)

注册流程内付费墙劝退敏感用户；国内版域名不可达；聚合毛利受上游挤压

OPPORTUNITY · 机会

子代理核验的"证据强度分级"方法论可输出为企业级信任标准

THREAT · 威胁

国内可及性存疑 (manus.cn 不可达); 上游 API 成本波动直接冲击毛利

策略建议·如果我是豆包工作的 PM

3 条建议全部由走查证据驱动，每条附依据章节、风险与落地第一步。

建议1·把"忠实性+引用健康度"产品化，抢占反幻觉心智

动作：豆包 S1/S3 的零编造是真实差异化（Kimi 静默虚构 4 处对照），但 S5 死链暴露引用短板——把来源健康度检查（死链检测/数字回验）做成生成前后的内置能力并公开营销。

依据：走查 S1/S3/S5 数据 (§5)；四家引用质量三态对照 (§7)。

风险：核验增加延迟与算力成本；公开对比可能引发竞品反评测。

落地第一步：在 S5 类任务的交付物中增加“来源健康度”徽章（死链/疑似编造/已验证三态），内部灰度两周。

建议 2·补齐工程交付的"最后一公里"严谨性

动作：S4 的 CDN 依赖让"单文件 HTML"不成立（Kimi 零依赖反超）——HTML 类交付默认内联全部依赖并自检；同时修复类"生成后表单状态回退"类问题（扣子的日期时区 bug 提供了反面教材）。

依据：S4 四家对照 (§5)；扣子日期 bug 案例 (§7)。

风险：内联依赖增大文件体积；自检规则需要维护成本。

落地第一步：给 html-artifact 交付管道加一条"外链资源 = 0"的发布门禁，复用扣子已验证的 implementation-contract 机制。

建议 3·收费体系上线"用量透明层", 避免信任断层

动作：豆包当前无额度 UI（用户零成本感知）+ 已收费（68-500 元/月）
——参考扣子的“消耗轨迹可观测”（实时百分比）与 Manus 的“余额数字明确”（两种透明各有盲区：前者无精确数、后者无实时轨迹），在会员体系内提供任务级消耗可视化，并对“调研类高消耗任务”给出预期管理。

依据：四家成本信号对照 (§6)：扣子实测"调研=32% 积分", Manus 明确额度且付费墙前置的转化代价清晰可见。

风险：透明可能抑制使用频次（双刃剑）；需要与产品增长目标平衡。

落地第一步：先做“月度用量报告”（只读、不打扰），验证用户对透明化的接受度再决定是否实时显示。

展望与可证伪信号：① 若 Kimi 下一版本修复虚构问题，判断 1 的分层将收敛（信号：会员体系重构后的产品声明）；② 若豆包 S5 类任务上线引用核验，建议 1 的窗口关闭；

③ 扣子积分消耗若在收费版持续走高，其 39.9 元定价将承压（信号：积分规则调整公告）。

方法论、局限与数据来源

报告的信用底线：证据分级五规范（PRD §7）。

证据分级五规范

① 证据分级

A=一手走查截图/产出物 · B=官方页面/文档 · C=权威媒体 · D=第三方估计；关键论断标等级

② 全程溯源

每条数据带来源 + 日期；体验结论可回溯到 evidence/ 截图库（40+ 张）

③ 口径统一

价格统一 RMB/月并注明汇率；用户数据标注口径与来源性质

④ 走查统一

同设备、新账号、同任务措辞（含预埋事实）；偏差与局限如实披露

⑤ 标注时效

所有数据区块标"数据截至"；过期即触发重跑

走查执行摘要

2026-09-30 至 10-01 两批 · 四家产品 × 五类任务（S1 写周报 / S3 数据分析 / S4 网页生成 / S5 信息调研 + 10-01 晚 S7 修 bug 补测批次），统一 prompt + 预埋事实（销售数据 3 处、bug 代码 2 处、评审文档 5 个分歧点）抓幻觉；**20 项任务全部完成**——其中 Manus S4 的交互实测受自动化环境限制，由用户人工补测闭环（两笔合计 ¥113.50 正确）；S7 批次的修复代码全部经走查员本地 harness 实测（含 buggy 原版基线对照）。每任务记录步数/耗时/断点/付费墙/aha/得分，77 张截图与 19 份产出转录归档于 data/evidence/。

局限声明（如实）

① 样本 1 人 1 次，非可用性测试；② S2/S6/S8 未走查，矩阵不完整处不外推；③ Manus S4 由用户人工补测闭环（自动化实测未覆盖，结果一致）；④ 豆包/Kimi 免费档走查，付费档体验未覆盖；⑤ 用户数据多为第三方估计（D 级）；⑥ AI 报告的引用核验抽样比例约 30-50%，非全量。

数据来源（走查证据 + 桌面调研）

- 豆包工作统合时间线与 MAU 3.82 亿：QQ 新闻（2026-08-21，Aily 8-13 更名/7-30 组织调整/3.82 亿 MAU）· 财新（2026-09-24，8-25 豆包工作发布）· 财联社（2026-06-24 收费）
- Kimi 会员重构与暂停新订阅：新浪财经（2026-07-27）· Kimi 官方帮助中心
- 扣子积分制与套餐：扣子官方文档（2026-01-19 套餐升级公告）· 火山引擎计费 FAQ
- Manus 定价与现状：manus.im/pricing（2026-09 查证）· 知乎专栏分析
- 腾讯 QClaw 停运、云栖大会千问办公：财新（2026-09-23/24）——由 Kimi/扣子调研报告发现，走查期外部复核
- 一手走查证据库：豆包工作 / Kimi / 扣子空间 / Manus 各任务截图与产出物（data/evidence/ · 77 张截图 + 19 份产出转录，证据等级）
- 走查判据与预埋事实设计：data/journey/tasks.md（S1-S8 统一 prompt + 判据权重）